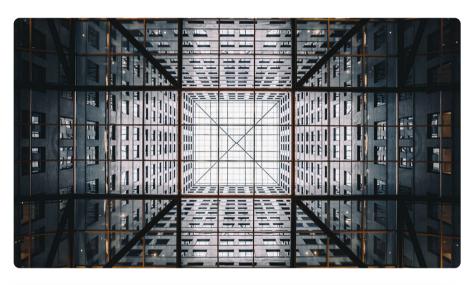
42 | IPC (下): 不同项目组之间抢资源, 如何协调?

2019-07-03 刘紹

趣谈Linux操作系统

讲入课程 >



讲述: 刘超

时长 15:55 大小 14.59M



IPC 这块的内容比较多,为了让你能够更好地理解,我分成 了三节来讲。前面我们解析完了共享内存的内核机制后, 今 天我们来看最后一部分,信号量的内核机制。

首先,我们需要创建一个信号量,调用的是系统调用 semget。代码如下:

■ 复制代码

```
1 SYSCALL DEFINE3(semget, key t, key, int, nsems, int, se
 2 {
           struct ipc namespace *ns;
           static const struct ipc ops sem ops = {
 5
                    .getnew = newary,
                    .associate = sem security,
                    .more checks = sem more checks,
           };
           struct ipc params sem params;
           ns = current->nsproxy->ipc ns;
10
           sem params.key = key;
11
           sem params.flg = semflg;
12
13
           sem params.u.nsems = nsems;
           return ipcget(ns, &sem ids(ns), &sem ops, &sem
14
15 }
```

我们解析过了共享内存,再看信号量,就顺畅很多了。这里同样调用了抽象的 ipcget,参数分别为信号量对应的sem_ids、对应的操作 sem_ops 以及对应的参数sem params。

ipcget 的代码我们已经解析过了。如果 key 设置为 IPC PRIVATE 则永远创建新的;如果不是的话,就会调用 ipcget_public.

在 ipcget_public 中,我们能会按照 key,去查找 struct kern_ipc_perm。如果没有找到,那就看看是否设置了 IPC_CREAT。如果设置了,就创建一个新的。如果找到了,就将对应的 id 返回。

我们这里重点看,如何按照参数 sem_ops,创建新的信号量会调用 newary。

```
1 static int newary(struct ipc namespace *ns, struct ipc
          int retval;
3
          struct sem array *sma;
4
          key t key = params->key;
5
          int nsems = params->u.nsems;
          int semflg = params->flg;
7
          int i;
8
9 .....
          sma = sem alloc(nsems);
10
11 .....
   sma->sem perm.mode = (semflg & S IRWXUGO);
   sma->sem_perm.key = key;
13
          sma->sem perm.security = NULL;
14
15 .....
         for (i = 0; i < nsems; i++) {
                  INIT LIST HEAD(&sma->sems[i].pending al
17
                  INIT LIST HEAD(&sma->sems[i].pending cc
18
19
                   spin lock init(&sma->sems[i].lock);
```

```
}
           sma->complex count = 0;
22
           sma->use global lock = USE GLOBAL LOCK HYSTERES
23
           INIT LIST HEAD(&sma->pending alter);
24
           INIT LIST HEAD(&sma->pending const);
25
           INIT LIST HEAD(&sma->list id);
26
           sma->sem nsems = nsems;
27
           sma->sem ctime = get seconds();
28
           retval = ipc addid(&sem ids(ns), &sma->sem perm
29 .....
30
           ns->used sems += nsems;
31 .....
           return sma->sem perm.id;
33 }
```

newary 函数的第一步,通过 kvmalloc 在直接映射区分配一个 struct sem_array 结构。这个结构是用来描述信号量的,这个结构最开始就是上面说的 struct kern_ipc_perm 结构。接下来就是填充这个 struct sem_array 结构,例如 key、权限等。

struct sem_array 里有多个信号量,放在 struct sem sems[] 数组里面,在 struct sem 里面有当前的信号量的数值 semval。

```
2
          int semval: /* current value */
          /*
           * PID of the process that last modified the se
           * Linux, specifically these are:
           * - semop
           * - semctl, via SETVAL and SETALL.
           * - at task exit when performing undo adjustm
8
10
          int sempid:
          spinlock t lock; /* spinlock for fine-gr
11
          struct list head pending alter; /* pending sing
12
          struct list head pending const; /* pending sing
13
          time t sem otime; /* candidate for sem ot
14
15 } cacheline aligned in smp;
```

struct sem_array 和 struct sem 各有一个链表 struct list_head pending_alter,分别表示对于整个信号量数组的 修改和对于某个信号量的修改。

newary 函数的第二步,就是初始化这些链表。

newary 函数的第三步,通过 ipc_addid 将新创建的 struct sem_array 结构,挂到 sem_ids 里面的基数树上,并返回相应的 id。

信号量创建的过程到此结束,接下来我们来看,如何通过 semctl 对信号量数组进行初始化。

```
1 SYSCALL DEFINE4(semctl, int, semid, int, semnum, int, c
2 {
 3
           int version:
           struct ipc namespace *ns;
           void user *p = (void user *)arg;
 5
           ns = current->nsproxy->ipc ns;
6
7
           switch (cmd) {
           case IPC INFO:
8
           case SEM INFO:
9
           case IPC STAT:
10
           case SEM STAT:
11
                    return semctl nolock(ns, semid, cmd, ve
12
13
           case GETALL:
14
           case GETVAL:
           case GETPID:
15
           case GETNCNT:
17
           case GETZCNT:
18
           case SETALL:
19
                    return semctl main(ns, semid, semnum, c
20
           case SETVAL:
                    return semctl setval(ns, semid, semnum,
21
22
           case IPC RMID:
23
           case IPC SET:
                    return semctl down(ns, semid, cmd, vers
24
           default:
25
26
                    return -EINVAL;
27
           }
28 }
```

•

这里我们重点看,SETALL 操作调用的 semctl_main 函数, 以及 SETVAL 操作调用的 semctl setval 函数。

对于 SETALL 操作来讲,传进来的参数为 union semun 里面的 unsigned short *array,会设置整个信号量集合。

```
1 static int semctl main(struct ipc namespace *ns, int s€
2
                   int cmd, void user *p)
3 {
4
           struct sem array *sma;
           struct sem *curr;
 5
           int err, nsems;
           ushort fast sem io[SEMMSL FAST];
7
           ushort *sem io = fast sem io;
8
9
           DEFINE WAKE O(wake q);
           sma = sem obtain object check(ns, semid);
10
11
           nsems = sma->sem nsems;
12 .....
13
           switch (cmd) {
14 .....
         case SETALL:
15
17
                   int i;
18
                   struct sem undo *un;
19 .....
20
                   if (copy from user(sem io, p, nsems*siz
21 .....
22
                   }
23 .....
                   for (i = 0; i < nsems; i++) {
24
                           sma->sems[i].semval = sem io[i]
25
```

```
26
                            sma->sems[i].sempid = task tgic
27
                    }
28
29
                    sma->sem ctime = get seconds();
                    /* maybe some queued-up processes were
                    do smart update(sma, NULL, 0, 0, &wake
                    err = 0;
32
33
                   goto out unlock;
34
           }
36 ....
37
      wake up q(&wake q);
38 .....
39 }
```

在 semctl_main 函数中,先是通过 sem_obtain_object_check,根据信号量集合的 id 在基数 树里面找到 struct sem_array 对象,发现如果是 SETALL 操作,就将用户的参数中的 unsigned short *array 通过 copy_from_user 拷贝到内核里面的 sem_io 数组,然后是一个循环,对于信号量集合里面的每一个信号量,设置 semval,以及修改这个信号量值的 pid。

对于 SETVAL 操作来讲,传进来的参数 union semun 里面的 int val,仅仅会设置某个信号量。

```
1 static int semctl setval(struct ipc namespace *ns, int
                   unsigned long arg)
3 {
          struct sem undo *un;
5
           struct sem array *sma;
           struct sem *curr;
6
           int err, val;
7
8
           DEFINE WAKE Q(wake q);
9 .....
          sma = sem obtain object check(ns, semid);
10
11 .....
     curr = &sma->sems[semnum];
12
13 .....
          curr->semval = val;
14
          curr->sempid = task tgid vnr(current);
15
          sma->sem ctime = get seconds();
16
17
          /* maybe some queued-up processes were waiting
           do smart update(sma, NULL, 0, 0, &wake q);
18
19 .....
          wake up q(&wake q);
20
21
          return 0;
22 }
```

在 semctl_setval 函数中,我们先是通过 sem_obtain_object_check,根据信号量集合的 id 在基数 树里面找到 struct sem_array 对象,对于 SETVAL 操作,直接根据参数中的 val 设置 semval,以及修改这个信号量值的 pid。

至此,信号量数组初始化完毕。接下来我们来看 P 操作和 V 操作。无论是 P 操作,还是 V 操作都是调用 semop 系统调用。

```
1 SYSCALL DEFINE3(semop, int, semid, struct sembuf user
                   unsigned, nsops)
2
3 {
          return sys semtimedop(semid, tsops, nsops, NULL
5 }
6
7 SYSCALL DEFINE4(semtimedop, int, semid, struct sembuf
                   unsigned, nsops, const struct timespec
8
9 {
10
           int error = -EINVAL;
           struct sem array *sma;
11
           struct sembuf fast sops[SEMOPM FAST];
12
           struct sembuf *sops = fast sops, *sop;
13
           struct sem undo *un;
14
15
           int max, locknum;
           bool undos = false, alter = false, dupsop = fal
           struct sem queue queue;
17
           unsigned long dup = 0, jiffies left = 0;
18
           struct ipc namespace *ns;
19
20
21
           ns = current->nsproxy->ipc ns;
22 .....
23
           if (copy from user(sops, tsops, nsops * sizeof(
24
                   error = -EFAULT;
                   goto out free;
25
           }
26
27
           if (timeout) {
28
```

```
29
                   struct timespec timeout;
                   if (copy from user(& timeout, timeout,
30
31
                   }
32
                   jiffies left = timespec to jiffies(& ti
33
           }
34 .....
           /* On success, find alloc undo takes the rcu re
           un = find alloc undo(ns, semid);
36
37 .....
           sma = sem obtain object check(ns, semid);
38
39 .....
40
           queue.sops = sops;
41
           queue.nsops = nsops;
           queue.undo = un;
42
43
           queue.pid = task tgid vnr(current);
           queue.alter = alter;
44
45
           queue.dupsop = dupsop;
46
47
           error = perform atomic semop(sma, &queue);
           if (error == 0) { /* non-blocking successfull pa
48
49
                   DEFINE WAKE Q(wake q);
50 .....
                   do smart update(sma, sops, nsops, 1, &w
51
52 .....
53
                   wake up q(&wake q);
                   goto out free;
54
           }
           /*
56
57
            * We need to sleep on this operation, so we pu
58
            * task into the pending queue and go to sleep.
59
            */
           if (nsops == 1) {
60
                   struct sem *curr;
61
                   curr = &sma->sems[sops->sem num];
62
63 .....
```

```
64
                    list add tail(&queue.list,
                                                     &curr->
66 .....
           } else {
67
68 .....
                   list add tail(&queue.list, &sma->pendir
70 .....
           }
71
72
73
           do {
74
                   queue.status = -EINTR;
                   queue.sleeper = current;
76
                   set current state(TASK INTERRUPTIBLE)
77
                   if (timeout)
78
                            jiffies left = schedule timeout
79
80
                   else
                            schedule();
81
82 .....
                    /*
83
                    * If an interrupt occurred we have to
84
85
                    */
                    if (timeout && jiffies left == 0)
87
                            error = -EAGAIN;
           } while (error == -EINTR && !signal pending(cur
88
89 .....
90 }
```

semop 会调用 semtimedop,这是一个非常复杂的函数。

semtimedop 做的第一件事情,就是将用户的参数,例如,对于信号量的操作 struct sembuf,拷贝到内核里面来。另外,如果是 P 操作,很可能让进程进入等待状态,是否要为这个等待状态设置一个超时,timeout 也是一个参数,会把它变成时钟的滴答数目。

semtimedop 做的第二件事情,是通过 sem_obtain_object_check,根据信号量集合的 id,获得 struct sem_array,然后,创建一个 struct sem_queue 表 示当前的信号量操作。为什么叫 queue 呢? 因为这个操作 可能马上就能完成,也可能因为无法获取信号量不能完成, 不能完成的话就只好排列到队列上,等待信号量满足条件的 时候。semtimedop 会调用 perform_atomic_semop 在实 施信号量操作。

```
1 static int perform_atomic_semop(struct sem_array *sma,
2 {
3         int result, sem_op, nsops;
4         struct sembuf *sop;
5         struct sem *curr;
6         struct sembuf *sops;
7         struct sem_undo *un;
8
9         sops = q->sops;
10         nsops = q->nsops;
11         un = q->undo;
12
```

```
13
            for (sop = sops; sop < sops + nsops; sop++) {</pre>
14
                     curr = &sma->sems[sop->sem num];
15
                     sem_op = sop->sem op;
16
                     result = curr->semval;
17
   . . . . . .
18
                    result += sem_op;
19
                    if (result < 0)
20
                             goto would block;
21
   . . . . . .
22
                    if (sop->sem flg & SEM UNDO) {
23
                             int undo = un->semadj[sop->sem
24
  . . . . .
25
                     }
            }
27
            for (sop = sops; sop < sops + nsops; sop++) {</pre>
28
29
                    curr = &sma->sems[sop->sem num];
                    sem op = sop->sem op;
31
                     result = curr->semval;
32
                    if (sop->sem flg & SEM UNDO) {
                             int undo = un->semadj[sop->sem
34
                             un->semadj[sop->sem num] = undc
                     }
                     curr->semval += sem op;
                     curr->sempid = q->pid;
38
            }
39
40
            return 0;
41 would block:
           q->blocking = sop;
42
            return sop->sem flg & IPC NOWAIT ? -EAGAIN : 1;
43
44 }
```

•

在 perform_atomic_semop 函数中,对于所有信号量操作都进行两次循环。在第一次循环中,如果发现计算出的 result 小于 0,则说明必须等待,于是跳到 would_block中,设置 q->blocking = sop 表示这个 queue 是 block 在这个操作上,然后如果需要等待,则返回 1。如果第一次循环中发现无需等待,则第二个循环实施所有的信号量操作,将信号量的值设置为新的值,并且返回 0。

接下来,我们回到 semtimedop,来看它干的第三件事情,就是如果需要等待,应该怎么办?

如果需要等待,则要区分刚才的对于信号量的操作,是对一个信号量的,还是对于整个信号量集合的。如果是对于一个信号量的,那我们就将 queue 挂到这个信号量的 pending_alter 中;如果是对于整个信号量集合的,那我们就将 queue 挂到整个信号量集合的 pending_alter 中。

接下来的 do-while 循环,就是要开始等待了。如果等待没有时间限制,则调用 schedule 让出 CPU;如果等待有时间限制,则调用 schedule_timeout 让出 CPU,过一段时间还回来。当回来的时候,判断是否等待超时,如果没有等待超时则进入下一轮循环,再次等待,如果超时则退出循环,返回错误。在让出 CPU 的时候,设置进程的状态为TASK_INTERRUPTIBLE,并且循环的结束会通过

signal_pending 查看是否收到过信号,这说明这个等待信号量的进程是可以被信号中断的,也即一个等待信号量的进程是可以通过 kill 杀掉的。

我们再来看, semtimedop 要做的第四件事情, 如果不需要等待, 应该怎么办?

如果不需要等待,就说明对于信号量的操作完成了,也改变了信号量的值。接下来,就是一个标准流程。我们通过DEFINE_WAKE_Q(wake_q)声明一个wake_q,调用do_smart_update,看这次对于信号量的值的改变,可以影响并可以激活等待队列中的哪些structsem_queue,然后把它们都放在wake_q里面,调用wake_up_q唤醒这些进程。其实,所有的对于信号量的值的修改都会涉及这三个操作,如果你回过头去仔细看SETALL和SETVAL操作,在设置完毕信号量之后,也是这三个操作。

我们来看 do_smart_update 是如何实现的。 do_smart_update 会调用 update_queue。

```
static int update_queue(struct sem_array *sma, int semr
{
    struct sem_queue *q, *tmp;
    struct list head *pending list;
```

```
5
           int semop completed = 0;
           if (semnum == -1)
 7
 8
                   pending list = &sma->pending alter;
 9
           else
                   pending list = &sma->sems[semnum].pendi
10
11
12 again:
           list_for_each_entry_safe(q, tmp, pending_list,
13
14
                   int error, restart;
15 .....
16
                   error = perform atomic semop(sma, q);
17
                   /* Does q->sleeper still need to sleep?
18
                   if (error > 0)
19
20
                            continue;
21
22
                   unlink queue(sma, q);
23 .....
24
                   wake up sem queue prepare(q, error, wak
25 .....
26
          return semop completed;
27
28 }
29
30 static inline void wake_up_sem_queue_prepare(struct sem
                                                 struct wak
31
32 {
33
          wake q add(wake q, q->sleeper);
34 .....
35 }
```

(

update_queue 会依次循环整个信号量集合的等待队列 pending_alter,或者某个信号量的等待队列。试图在信号量的值变了的情况下,再次尝试 perform_atomic_semop进行信号量操作。如果不成功,则尝试队列中的下一个;如果尝试成功,则调用 unlink_queue 从队列上取下来,然后调用 wake_up_sem_queue_prepare,将 q->sleeper 加到 wake_q 上去。q->sleeper 是一个 task_struct,是等待在这个信号量操作上的进程。

接下来,wake_up_q 就依次唤醒 wake_q 上的所有 task_struct,调用的是我们在进程调度那一节学过的 wake_up_process 方法。

```
void wake up g(struct wake g head *head)
2 {
           struct wake q node *node = head->first;
           while (node != WAKE O TAIL) {
                    struct task struct *task;
 6
                   task = container of(node, struct task s
8
                   node = node->next;
10
11
                   task->wake q.next = NULL;
12
13
                   wake up process(task);
14
                   put task struct(task);
15
           }
```

至此,对于信号量的主流操作都解析完毕了。

其实还有一点需要强调一下,信号量是一个整个 Linux 可见的全局资源,而不像咱们在线程同步那一节讲过的都是某个进程独占的资源,好处是可以跨进程通信,坏处就是如果一个进程通过 P 操作拿到了一个信号量,但是不幸异常退出了,如果没有来得及归还这个信号量,可能所有其他的进程都阻塞了。

那怎么办呢? Linux 有一种机制叫 SEM_UNDO,也即每一个 semop 操作都会保存一个反向 struct sem_undo 操作,当因为某个进程异常退出的时候,这个进程做的所有的操作都会回退,从而保证其他进程可以正常工作。

如果你回头看,我们写的程序里面的 semaphore_p 函数和 semaphore_v 函数,都把 sem_flg 设置为 SEM_UNDO, 就是这个作用。

等待队列上的每一个 struct sem_queue, 都有一个 struct sem_undo, 以此来表示这次操作的反向操作。

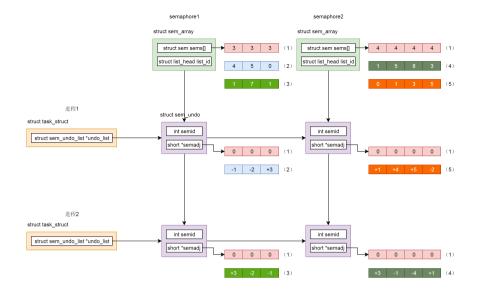
```
1 struct sem queue {
2
          struct list head
                                 list; /* queue of pe
          struct task struct
                                 *sleeper; /* this proce
3
          struct sem undo
                                 *undo; /* undo struct
                                 pid; /* process id
          int
                                 status; /* completion
          int
                                 *sops; /* array of pe
          struct sembuf
7
          struct sembuf
                                 *blocking; /* the opera
                                 nsops; /* number of c
          int
                                 alter; /* does *sops
         hoo1
10
                                 dupsop; /* sops on mor
         bool
11
12 };
```

在进程的 task_struct 里面对于信号量有一个成员 struct sysv_sem,里面是一个 struct sem_undo_list,将这个进程所有的 semop 所带来的 undo 操作都串起来。

```
11 struct sem undo {
           struct list head
                                    list proc;
12
                                                     /* per-
                                                      * all
13
                                                      * rcu
14
                                                     /* rcu
15
           struct rcu head
                                    rcu;
           struct sem undo list
                                                     /* back
16
                                    *ulp;
           struct list head
                                    list id;
                                                     /* per
17
                                                      * all
18
19
           int
                                    semid:
                                                     /* sema
           short
                                    *semadj;
                                                     /* arra
20
                                                     /* one
21
22 };
23
24 struct sem undo list {
25
           atomic t
                                    refcnt;
           spinlock t
                                    lock;
27
           struct list head
                                    list proc;
28 };
```

为了让你更清楚地理解 struct sem_undo 的原理,我们这里举一个例子。

假设我们创建了两个信号量集合。一个叫 semaphore1,它包含三个信号量,初始化值为 3,另一个叫 semaphore2,它包含 4 个信号量,初始化值都为 4。初始化时候的信号量以及 undo 结构里面的值如图中 (1) 标号所示。



首先,我们来看进程 1。我们调用 semop,将 semaphore1 的三个信号量的值,分别加 1、加 2 和减 3,从而信号量的值变为 4,5,0。于是在 semaphore1 和进程 1 链表交汇的 undo 结构里面,填写 -1,-2,+3,是 semop 操作的反向操作,如图中 (2) 标号所示。

然后,我们来看进程 2。我们调用 semop,将 semaphore1 的三个信号量的值,分别减 3、加 2 和加 1,从而信号量的值变为 1、7、1。于是在 semaphore1 和进程 2 链表交汇的 undo 结构里面,填写 +3、-2、-1,是 semop 操作的反向操作,如图中 (3) 标号所示。

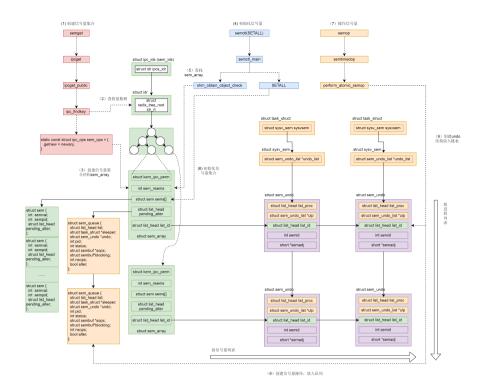
然后,我们接着看进程 2。我们调用 semop,将 semaphore2 的四个信号量的值,分别减 3、加 1、加 4 和减 1,从而信号量的值变为 1、5、8、3。于是,在 semaphore2 和进程 2 链表交汇的 undo 结构里面,填写 +3、-1、-4、+1,是 semop 操作的反向操作,如图中 (4) 标号所示。

然后,我们再来看进程 1。我们调用 semop,将 semaphore2 的四个信号量的值,分别减 1、减 4、减 5 和 加 2,从而信号量的值变为 0、1、3、5。于是在 semaphore2 和进程 1 链表交汇的 undo 结构里面,填写 +1、+4、+5、-2,是 semop 操作的反向操作,如图中 (5) 标号所示。

从这个例子可以看出,无论哪个进程异常退出,只要将 undo 结构里面的值加回当前信号量的值,就能够得到正确 的信号量的值,不会因为一个进程退出,导致信号量的值处 于不一致的状态。

总结时刻

信号量的机制也很复杂,我们对着下面这个图总结一下。



- 1. 调用 semget 创建信号量集合。
- 2. ipc_findkey 会在基数树中,根据 key 查找信号量集合 sem_array 对象。如果已经被创建,就会被查询出来。例 如 producer 被创建过,在 consumer 中就会查询出来。
- 3. 如果信号量集合没有被创建过,则调用 sem_ops 的 newary 方法,创建一个信号量集合对象 sem_array。例 如,在 producer 中就会新建。
- 4. 调用 semctl(SETALL) 初始化信号量。
- 5. sem_obtain_object_check 先从基数树里面找到 sem_array 对象。

- 6. 根据用户指定的信号量数组,初始化信号量集合,也即初始化 sem_array 对象的 struct sem sems[] 成员。
- 7. 调用 semop 操作信号量。
- 8. 创建信号量操作结构 sem queue, 放入队列。
- 9. 创建 undo 结构, 放入链表。

课堂练习

现在,我们的共享内存、信号量、消息队列都讲完了,你是不是觉得,它们的 API 非常相似。为了方便记忆,你可以自己整理一个表格,列一下这三种进程间通信机制、行为创建xxxget、使用、控制 xxxctl、对应的 API 和系统调用。

欢迎留言和我分享你的疑惑和见解, 也欢迎可以收藏本节内容, 反复研读。你也可以把今天的内容分享给你的朋友, 和他一起学习和进步。



趣谈 Linux 操作系统

像故事一样的操作系统入门课

刘超

网易杭州研究院 云计算技术部首席架构师



新版升级:点击「♀请朋友读」,10位好友免费读,邀请订阅更有现金奖励。

© 版权归极客邦科技所有,未经许可不得传播售卖。 页面已增加防盗追踪, 如有侵权极客邦将依法追究其法律责任。

上一篇 41 | IPC (中): 不同项目组之间抢资源, 如何协调?

下一篇 43 预习 | Socket通信之网络协议基本原理

精选留言 (5)





请问一下老师,在应用程序开发中,像信号量 共享内存 这些内核资源怎么样防止泄漏呢?比如有进程a和b用共享 内存共享数据,共享内存资源由教程a申请和维护,但由于异常情况导致教程异常退出导致共享内存资源没有释放,导致了申请的共享内存没有释放。这种情况一般怎… 展开 >







安排

2019-07-04

schedule_timeout调用完后,会让出cpu,过一段时间还会回来。这个过一段时间是多长时间啊?是说超时之后返回来吗,还是被其它信号打断睡眠之后回来?

展开٧







莫名

2019-07-04

老师,有没有打算讲一下POSIX IPC呢?

展开~







免费的人

2019-07-03

消息队列的内核实现好像没讲过?

展开٧







Sharry 2019-07-03

终于把共享内存和信号量集合的知识串联在一起了,其中的操作的确有些复杂

共享内存若想实现进程之间的同步读写, 则需要配合信号 量共同使用...

展开~



